Описание алгоритма

Вдовин Максим

25 ноября 2020 г.

Дано α и слово $u \in \{a,b,c\}*$. Нужно найти длину наибольшего префикса u, принадлежащего L.

Решать эту задучу буду методом динамического программирования. Пусть у нас есть строки: reg - регулярное выражение, str - слово, для которого нужно найти наибольший общий префикс принадлежащий языку. Также пусть длинна |reg|=m, а |str|=n. Суть алгоритма в том, чтобы для каждого символа регулярки понять какую часть слова она распознаёт. Заведем массив булей dp[l][i][j], где l - номер текущего символа из reg, i и j - левая и правая граница, той части слова, которая считывается регулярным выражением. Значение true в dp[l][i][j] означает, что reg[l] принимает в себя подслово [i,j).

Далее я покажу как подсчитать dp в зависимости от разных случев reg[l]

- 1. Если reg[l] 1, то $\forall i \quad dp[l][i][i] = true$. Очевидно, что таким образом мы задаём пустое слово.
- 2. Если reg[l] буква, то $\forall i,$ если (str[i] == reg[l]) мы записываем dp[l][i][i+1] = true
- 3. Если reg[l]= " + ", то мы будем искать такие l_0 и l_1 , что они являются операндами для reg[l]. Далее подсчитаем $\forall i,j \quad dp[l][i][j] = dp[l_0][i][j] \mid dp[l_1][i][j]$
- 4. Если reg[l] = ".",то мы будем искать такие l_0 и l_1 , что они являются операндами для reg[l]. Далее подсчитаем возьмем некоторый разделитель pivot, который будет изменяться $\forall i, j$, так что $i \leq pivot \leq j$. Массив dp теперь будет считаться по следующей формуле:

$$\forall i, j \quad dp[l][i][j] = dp[l][i][j] \mid\mid (dp[l_0][i][pivot] \mid\mid dp[l_1][pivot][j])$$

Здесь мы как бы говорим, что подслово str[i...j) может быть получено из регулярного выражения, соответствующего reg[l], если существует разбиение этого слова на два слова: str[i...j) = str[i...pivot)str[pivot...j) и каждое из этих двух слов может быть получено из соответствующих операндов для reg[l].

5. Если reg[l] = " * ",то мы будем искать такое l, что оно является операндом для reg[l]. Далее подсчитаем возьмем некоторый разделитель — pivot, который будет изменяться $\forall i, j$, так что $i \leq pivot \leq j$. Массив dp теперь будет считаться по следующей формуле:

$$\forall i, j \quad dp[l][i][j] = dp[l][i][j] \mid\mid (dp[l_0][i][pivot] \mid\mid dp[l_1][pivot][j])$$

Здесь мы как бы говорим, что подслово str[i...j) может быть получено из регулярного выражения для reg[l], если существует разбиение этого слова на несколько слов: $str[i...j) = str[i...i_1) str[i_1...i_2) \dots str[i_k...j)$ и каждое из этих слов может быть получено из регулярного выражения для $reg[l_0]$. Это в свою очередь эквивалентно тому, что существует разбиение слова str[i...j) на два слова: $str[i...j) = str[i...i_l) str[i_l...j)$ и первое слово может быть получено из регулярного выражения для reg[l], а второе из PB для $reg[l_0]$.